

工学硕士学位论文

基于灰色理论和 BP 神经网络
交通流预测模型研究

陈纲

哈尔滨工业大学

2006 年 6 月

国内图书分类号: U491.1+12

国际图书分类号: 629

工学硕士学位论文

基于灰色理论和 BP 神经网络 交通流预测模型研究

硕士研究生: 陈 纲

导 师: 王 健 副教授

申 请 学 位: 工学硕士

学 科、专 业: 交通运输规划与管理

所 在 单 位: 深圳研究生院

答 辩 日 期: 2006 年 6 月

授予学位单位: 哈尔滨工业大学

Classified Index: U491.1+12

U.D.C: 629

Dissertation for the Master Degree of Engineering

**PREDICTION OF TRAFFIC FLOW
BASED ON GREY THEORY AND BP
NEURAL NETWORKS**

Candidate:	Chen Gang
Supervisor:	Associate Prof. Wang Jian
Academic Degree Applied for:	Master of Engineering
Specialty:	Transportation planning and Management
Affiliation:	Shenzhen Graduate School
Date of Oral Examination:	June, 2006
University:	Harbin Institute of Technology

摘要

近年来随着交通技术的进步，交通设施不断得到改善，智能交通系统（ITS, Intelligent Transportation System）的应用也越来越广泛。智能交通系统中的交通诱导子系统是出行和运输管理系统的主要内容，而准确的短期交通流预测对于合理诱导和控制交通、减少交通拥挤等重要作用。目前的交通流预测模型存在着运算时间长、精度不高等缺点。

本文的研究目的在于建立一个能够克服上述缺点的交通流预测模型。灰色预测模型 GM(1,1)最大的特点就是算法简单、可利用较少数据建模。这给建模和运算带来了方便，但是灰色预测模型对于具有波动性的系统来说预测的效果不是很理想，而且预测的准确率会随着时间的外推而逐渐降低。神经网络对于非线性系统的预测具有良好的性能，但是在对网络进行训练时，往往需要大量的数据。本文以灰色预测模型为基础，利用灰色预测模型算法简单、建模所用数据少的优点以及 BP 神经网络对非线性系统预测性能良好的优点，通过 BP 神经网络对灰色预测模型进行修正，最后建立了一个组合模型。在求解算法中对 BP 神经网络算法易陷入局部最小点的缺点，结合动量法和自适应学习率的方法对算法进行了改进。

通过收集某路段的交通流量数据，利用建立的模型构造了一个算例，通过 Matlab 软件编程计算，并与单一的灰色预测模型和 BP 神经网络模型的预测效果进行了对比，结果表明，组合模型能够充分发挥各单一模型的优点同时弱化了单一模型的缺点，比单一模型的预测结果理想。

关键词 智能交通系统；交通流；灰色预测模型；BP 神经网络

Abstract

Recently with the progress of the traffic technology, the means of transportation is proved also and the application of ITS (Intelligent Transportation System) is more extensive. The traffic inducement subsystem is the primary contents of transportation management subsystem. The precise prediction of short period traffic flow is as an important role in giving out the agreeable inducement and controlling of the next time to realize rather route choice and decrease the traffic jam. Previously the model of prediction of traffic flow have disadvantage that the time of operation is too long and the precision is low.

In this paper, we aim at overcoming the disadvantage of the prediction model that referred above. The merit of grey model GM(1,1) is that the arithmetic is simple and it can use few data to construct the model, these bring the facility of constructing model but the grey model to predict the result of the fluctuating system cursorily and the precision rate decreasing with the time going on. In the end we construct a combination model. During the operation we improve the BP arithmetic to avoid to getting into the partial least point.

By using traffic flow data of some road we construct a example and by use of Matlab to program .We contrast the new combination model to the single grey and BP neural network model. The result show that the combination model can take full advantage of every single model and avoid the disadvantage and the result of prediction is super than that single model to draw.

Keywords ITS; traffic flow; grey prediction model; BP neural network

目录

摘要	I
Abstract	II
 第 1 章 绪论	 1
1.1 课题背景及研究意义	1
1.2 国内外研究现状	1
1.2.1 国外研究现状	2
1.2.2 国内研究现状	4
1.2.3 国内外研究现状分析	5
1.3 本文主要内容	6
1.4 研究的方法及技术路线	7
第 2 章 基于灰色理论的交通流预测模型	9
2.1 交通流特性及预测方法分析	9
2.1.1 交通流预测方法及分类	9
2.1.2 短期交通流的特性分析	10
2.2 灰色系统模型的原理及改进	11
2.2.1 灰色系统模型的原理	11
2.2.2 GM(1,1) 模型的改进	13
2.3 基于灰色理论的交通流预测模型	13
2.3.1 灰色交通流预测模型的原始序列处理	13
2.3.2 灰色交通流预测模型的参数确定	14
2.3.3 灰色交通流预测模型的适用条件	16
2.4 灰色交通流预测模型算例	17
2.5 本章小结	20
第 3 章 基于神经网络的交通流预测模型	21
3.1 神经网络模型的原理	21
3.2 基于 BP 神经网络的交通流预测模型	22
3.2.1 神经网络交通流预测的方法	22
3.2.2 BP 神经网络模型	24
3.3 基于 BP 神经网络交通流预测模型算例	26

3.4 本章小结.....	29
第 4 章 灰色 BP 神经网络交通流预测模型.....	30
4.1 基于灰色系统和神经网络的交通流预测模型.....	30
4.1.1 灰色系统与神经网络的融合.....	30
4.1.2 灰色 BP 神经网络交通流预测模型的建立.....	31
4.2 灰色 BP 神经网络交通流预测模型的程序实现.....	32
4.3 灰色 BP 神经网络交通流预测模型的应用分析.....	34
4.3.1 原始数据序列的拟合及预测.....	34
4.3.2 灰色 BP 模型与灰色模型和 BP 模型的比较.....	36
4.3.3 对灰色 BP 模型和单一灰色预测模型的进一步比较.....	37
4.4 本章小结.....	40
参考文献.....	42
附录.....	45
攻读学位期间发表的学术论文.....	52
哈尔滨工业大学硕士学位论文原创性声明.....	53
哈尔滨工业大学硕士学位论文使用授权书.....	53
哈尔滨工业大学硕士学位论文涉密论文管理.....	53
致谢.....	54

第1章 绪论

1.1 课题背景及研究意义

近年来随着交通运输事业的发展，智能交通系统（ITS，Intelligent Transportation System）系统逐渐得到广泛应用。ITS 包括多个子系统，如：出行和运输管理系统、公共交通运输管理系统、电子收费系统、商业车辆运行系统、紧急情况管理系统、先进车辆安全系统、信息管理系统等。其中交通控制和诱导子系统是出行和运输管理系统的一部分内容，也是 ITS 研究的热门课题。而短期交通流预测在交通诱导中扮演着重要的角色。它的原理是通过实时得到的交通信息去滚动预测未来几分钟的交通状况，将预测的结果传送到先进的交通信息系统（ATIS, Advanced Transportation Information System）以及先进的交通管理系统（ATMS, Advanced Transportation Management System）当中，这样便能更好的为出行者提供实时有效的信息，合理诱导出行者的出行行为，减少行程时间，减少交通拥挤。这里提出的短期交通流预测是微观意义上的，主要是针对交通管理与控制的，与中观和宏观上的交通流预测有本质的区别，它们主要是针对规划的。

以往的交通流预测模型存在着模型的运算复杂，要求使用大量数据的缺点，同时也因此制约了运算速度。灰色预测模型具有短期预测精度高，预测使用数据少的优点，但是对于具有波动性的系统预测不够准确。通过对基于灰色理论的 BP 神经网络交通流预测的研究，利用灰色系统理论方法能使用较少的数据进行预测建模的特点，利用 BP 神经网络对非线性系统良好的预测性能，建立以灰色预测模型为主，通过 BP 神经网络进行调整的组合模型。从而减少运算时间，降低预测时间的延迟。

1.2 国内外研究现状

国内外关于短期交通流预测的研究，总体上可分为两种类型：一类是非组合模型，一类是组合模型。非组合模型：时间序列模型，卡尔曼滤波模型，指数平滑模型，参数回归模型，KARIMA 算法，基于小波理论的方法，基于多维分形的方法，谱分析法状态空间重构模型等；组合模型：主要是其他方法与

神经网络相结合的复合模型。

1.2.1 国外研究现状

1.2.1.1 在提高运算速度方面所作的研究

关于减小网络规模的做法：1997 年 Dougherty 和 Cobbett^[1]两人针对神经网络在短期交通流预测中的应用时，存在着大量参数的确定问题，提出了利用弹性测试的方法来减小网络规模的一种递推技术。神经网络最初的训练问题是确定合适的输入参数。在这项研究中所用的数据包括：流量、流速、占有率。包括了非高峰时段和高峰时段以及事件的条件，最初的试验是以一分钟为时段的，不是很成功。因为这样的随机性很大，同时由于考虑每一个单独的车道的数据更加剧了这种随机性。因此数据结合了非机动车道的数据，并且时段划分为五分钟。

用弹性分析法来理解训练的网络，通过分配给每一个输入结点的扰动性分析进行分析以及观察结果的运动。通过使用这种方法每个结点的重要性可以得到评价。

对于网络的测试和调整训练包括三方面：1) 对集合的初步训练：最初较大的网络通过可能获得的数据进行训练，集合包括了试验点的所有数据；2) 用弹性测试检验神经网络，观测输出数据随每一个输入数据变化的规律；3) 最后的训练是使用大量的数据包括例子进行训练，确定代表网络特性的数据点。最后对网络的性能进行评价并用统计分析的方法给出了预测准确的量度。

1.2.1.2 在提高预测的准确率方面的研究

1997 年 Corinne Ledoux^[2]建立了一个基于神经网络的交通流模型，主要是为了与实时调整的城市交通控制系统相结合。这里提出的神经网络是建立在局部神经网络协作的基础上的，每一个神经元负责模拟一个信号路段。信息的交换是在各个局部神经网络之间进行的。这样便能够在网络大上形成交通流的模拟。基于神经网络的交通流模型按单个信号路段的标准以及在结点处的标准分为两类。对于预测的结果给出了一种最小化分析标准，这种标准是在前一时段的预测基础上计算出来的。这样当前这些对输入数据的转换的质量也能被评价出来，在目前的所有数值中，如果实际的标准值是最小的，那么这些转换就是最有利的。

2001 年 Haibo Chen^[3]等提出了一种动态算法。通过实验对比，这种新算法能提高对预测的准确率。这种算法的基础是一种资源分配网络(RAN)算法。它

能够提供一种连续学习的计划。在这种情况下数据是按顺序输入网络的，每一个数据点因为没有存储完备的数据可能被丢弃。通过动态地增加一个隐藏单元网络的性能能够得到改善。这个单元把输入的模式作为各自的中心。网络因此在任何学习的阶段能够被使用，也能够任何工作的阶段被训练。RAN 是一个单一隐藏层的网络，它的输出相应于输入模式是一个隐藏个体的线性结合模式。当输入模式输入给 RAN 时，RAN 逐渐生成新的单元来减少性能的误差。隐藏单元的宽度和中心值在学习的过程中能够被调整。新的隐藏单元的分配由两个条件决定：（1）如果当前的输入与存在的中心距离很大；（2）如果期望的输出值与网络的输出值差异很大。如果一个输入模式不满足这两个条件，那么网络上的参数将会用最小均方差算法来调整。由于动态网络模型不是涉及到所有的数据，通过调查发现利用三个参数说明数据的选择是适合的： Q_0 是一个确定在梯度方向允许随机步骤的数量标准； e'_{\min} 是一个增加隐藏单元的标准； e_{\min} 预测误差的最小值。对偶然事件的数据的训练和测试进行了评价。首先是训练网络：（1）首先动态网络用所有的数据进行；（2）用偶然事件发生时附近的数据进行训练；（3）用最初的五个隐藏单元作为数据的固定点。三种不同的网络间的区别是前两者有隐藏单元这些单元在接收数据和运行数据时允许自由移动，如果这些单元不固定的话当新的数据出现的时候单元中心将持续的转移。但是没有任何一个网络在数据中变量的数量上获得解释，通过固定前五个单元，这些解释性的能力被重新训练，任何一个新的单元都这样被强制增强解释性的能力。

2005 年 Quek 和 Singh^[4] 提出一种基于 yager 推论的神经网络叫 pop-yager FNN，FNN 的训练包括了两个阶段：（1）模糊关系引出阶段，用模拟学习量子化的方法；（2）规则确定阶段，用一个新的单个通过惰性 pop 学习算法。基于 yager 原则的模糊系统是一类专家系统。最初的缺点是缺少准确的描绘模糊关系函数。人工神经网络是容错系统，拥有学习、反馈、归纳以及从训练数据中调整的能力。模糊神经网络是一个混合结构，神经网络具有学习和优化的能力。基于 yager 原则的模糊系统具有推理的能力。系统的关键问题是关系函数的选择的问题，而对于神经网络是用模糊理论来克服神经网络隐藏层的不透明性。yager 原则网络是基于 yager 推论原则的。yager 推论原则计算输入相异度时是用先行原则来引出以跟随原则计算的相异度，并因此得到结果。一个有利的条件是真值限制方法论，是说输入的值与先前的值匹配的越准确其输出与结果匹配的也越准确。pop-yager FNN 的系统结构对于一个多输入多输出系统

是一个六层神经网络每一层执行一个具体的操作。数据在输入前都要进行模糊化处理，在最后的输出语言层在对模糊数据进行翻译。

1.2.2 国内研究现状

1.2.2.1 基于神经网络预测

1998 年吉林工业大学初连禹和杨兆升^[5]提出了一种模糊神经网络的预测模型，这种模型基于模糊控制建立一个模糊预测模型用神经网络记忆模糊模型中的模糊规则。用当前的实测流量、历史流量、平均速度等作为输入量，并与基于历史数据和时间序列方法建立的模型进行了比较，与这两种方法相比模糊神经网络方法没有时间上的延迟。神经网络采用了一个三层的 BP 神经网络。其中隐藏层的功能函数采用双曲正切函数，权重按照随机方式初始化，并按照最陡下降法对权重系数进行调整。

王宏杰，林良明^[6]等提出了基于改进的 BP 神经网络理论模型的路面交通流时序的预测算法，针对于 BP 神经网络的学习率，用动量法对网络的收敛性进行优化。BP 神经网络最初是通过每一个样本进行训练最后确定网络的参数，这样的训练方法的缺点就是需要很长的时间并且收敛的速度也较慢。文章采用了一种积累误差的成批处理的方法来解决这个问题。虽然是采用了积累误差的方法但是 BP 算法仍然存在收敛速度慢的问题。因此文章讨论了通过调整学习率的方法来提高收敛速度。调整的原则是使它的每一步保持尽可能大的值，又不至于使学习过程产生振荡。因此采用了启发式调整。BP 网络的另一个缺点是容易陷入局部最小点，所谓的动量法就是在原有权值调整的基础上再加上一个动量向。在对输入数据的预处理上文章采用了按比例缩放的方法。最后文章还将改进的算法与几种算法进行了比较从计算次数上和平均误差上。

2002 年谭国真和丁浩^[7]提出了一种基于线性独立函数的智能神经元模型。从广义的神经元讲，它能够大大地增强神经元的信息存储能力。文章指出了在大量样本存在的情况下 BP 神经网络存在收敛速度慢的情况。以往的研究中人们用线性独立函数对神经网络输入层进行预处理，使神经网络具有较好的映射效果。文章提出了拓展神经元的思想也就是所谓的广义神经元，采用的是正弦和余弦函数对神经元进行构建。通过这种拓展能够增强神经元存储信息的能力。对输入数据的选择，通过相关路段的相关性分析，选择相关系数大的进行输入。

2003 年李英^[8]等人提出了一种演化的神经网络。文章指出了用神经网络进

行预测时主要有三方面的问题：1) 网络结构的确定；2) 训练样本的选择；3) 训练集、实证集、检验集的划分。文章采用了遗传算法与神经网络相结合来对网络的结构进行确定。这种网络因此称为演化神经网络。神经网络的演化主要包括三个方面：1) 连接权的进化 采用遗传算法能避免传统的 BP 神经网络陷入局部最小值的缺点；2) 网络结构的进化 主要是指神经网络的拓扑结构包括节点数、层数、连接方式、节点传递函数等。利用遗传算法进化神经网络结构可以减少对人为因素的依赖；3) 学习规则的进化。

2004 年杨世坚和贺国光^[9]两人提出了模糊 C 均值和神经网络相结合的预测方法。文章指出了神经网络对于短期交通流预测很有效，但是也存在缺点即当异常交通流出现时难以准确判断未来交通流的运行状态，而模糊神经网络对于 30 分钟以上的交通流预测的效果比较好，对于更短的交通流预测相对困难。针对两者的特点这篇文章将这两者进行了结合。模糊 C 聚类方法是建立在误差平方和的基础上的，以样本属于某类的隶属等级来表示样本与某类的距离。这样通过这些方法对数据进行分类。

1.2.2.2 基于灰色理论预测

2002 年孙燕和陈森发^[10]针对无检测器的交叉口的交通流量数据有限的情况建立了一个自适应灰色预测模型。文章首先介绍了全数据灰色模型。全数据模型对系统的刻化会随着时间的外推而逐渐失真，因此为避免这一缺点，可以先用已知数列建立的 GM(1, 1) 模型预测一个值然后补充一个新信息数据到已知数列中，同时去掉一个最老的数据使序列等维，接着再建立 GM(1, 1) 模型，这样逐个滚动预测直到完成预测为止，称为自适应 GM(1, 1) 模型。

2004 年陈淑燕和陈家胜^[11]结合遗传算法和最小二乘法提出了一种改进的灰色模型。将灰色模型归结为某类含若干待定参数的微分方程，离散化该微分方程，使用最小二乘法确定其中的参数。将自适应与等维递推的思想引入改进的 GM(1, 1) 模型，预测效果得到显著的提高。

1.2.3 国内外研究现状分析

在短期交通流预测领域目前应用最多的是基于神经网络的组合模型。

神经网络对于非线性问题的预测具有良好的性能，但是同时也存在着缺点：网络的训练需要大量的原始数据；隐藏层神经元的数量需要由经验来确定，有一定的任意性缺乏理论的指导；神经网络还存在着局部最小和收敛速度慢等缺点。目前，国内外关于神经网络预测模型研究的比较多，也取得了一定

的成果, 预测的平均误差大概为 7%—12%。但是, 神经网络预测模型建模过程相对比较复杂, 模型的拟合速度较慢, 不能很好地适应短时间实时预测的要求, 而且神经网络需要大量自我学习数据, 数据不足会导致不好的预测结果。

国内外关于神经网络在短期交通流预测上的研究可概括为以下两个方面的问题: 1) 原始数据的处理 这包括选取的主要参数的确定以及在输入层的转换; 2) 隐藏层节点数的确定, 连接权值的调整方法。

针对这两个方面产生了遗传算法神经网络, 模糊神经网络等组合模型。但是最根本的原因还是数据的选择, 数据的选择直接关系到后来的计算, 数据过多网络的结构体系庞大, 计算速度慢, 影响到模型的在线应用。数据选择的过少, 预测的准确性就难以保证。

1.3 本文主要内容

(1) 灰色系统交通流预测模型 GM(1,1)

1) 建模前的数据处理即灰色序列生成

这里对于交通流预测, 将各个时段的交通流量作为灰色序列生成的原始序列。灰色系统理论是通过挖掘原始数据, 整理来寻求其变化规律的。灰色序列生成的方法有: ①均值生成算子, 这种方法适用于构造新数据、填补原序列空穴、生成新序列的方法; ②级比生成算子, 当序列的起点和终点为空穴时, 采用这种方法生成序列; ③累加生成算子与累减生成算子。

累加生成算子是灰色系统理论中重要的一种序列生成方法。累减生成是在获取增量信息时常用的生成, 累减生成对累加生成起还原作用。累加生成算子和累减生成算子是一对互逆的序列算子。本论文将采用累加算子和累减算子以及均值算子来生成序列。

2) 模型的求解

本文采用最小二乘法对模型中的参数进行确定。

(2) 灰色人工神经网络交通流预测组合模型

由预测值和实际值之间的偏差, 可以得到一系列 BP 神经网络训练的输入样本, 通过神经网络进行训练最后可以得出参差的预测值。最后得出了由灰色模型和 BP 神经网络模型组合生成的新的预测模型。

本文在 BP 神经网络设计时采用了典型的三层前馈神经网络。由于神经网络存在着收敛速度慢和易陷入局部最小点的缺点, 本文在神经网络设计时采用动量法和学习率自适应调整两种策略, 一方面提高了算法的速度, 另一方面也

增加了算法的可靠性，动量法能降低网络对误差曲面局部细节的敏感性，有效地抑制网络陷于局部极小；自适应调整学习率有利于缩短学习时间。最后通过利用 MATLAB 编程实现。

（3）案例分析

本文利用某路段收集的交通流量数据，通过 Matlab 编程构造了一个算例。同时与单一的灰色模型以及单一的 BP 神经网络模型进行了比较。最后对各种算法的预测结果进行分析。

1.4 研究的方法及技术路线

本论文研究的路线将按如下步骤进行：

（1）明确研究的目标：对于现有模型存在着规模庞大，运算速度慢的缺点，本论文利用灰色预测模型可少数据建模，算法简单的优点结合 BP 神经网络对模型进行调整，建立了一个组合模型，期望在精度和运算速度上取得了满意的效果。

（2）交通流特性及现有预测方法分析

对交通流的特性进行分析，对各单一模型存在的缺点及优点进行分析，分析不同模型之间组合的可行性。组合模型可以扬长避短，在建模的过程中注意算法的改进，尤其是在提高运算速度上的改进。灰色模型算法简单，运算速度快，但是对交通流这样具有波动性的系统，预测的效果不是很好。

（3）模型的建立

通过预测结果与实际值之间的残差序列，建立以残差序列为输入对的 BP 神经网络模型，经过训练可以做出对残差的预测值，从而建立了以灰色模型为基础并通过 BP 神经网络进行修正的组合模型。

（4）案例分析

以某路段收集的交通流量作为已知的序列，由建立的组合模型对交通流进行预测。同时分别建立单一的灰色模型和单一的 BP 神经网络模型，并分别用单一模型对交通流进行预测。对各预测结果进行比较分析。并对组合模型的效果进行评价。

本文技术路线见图：

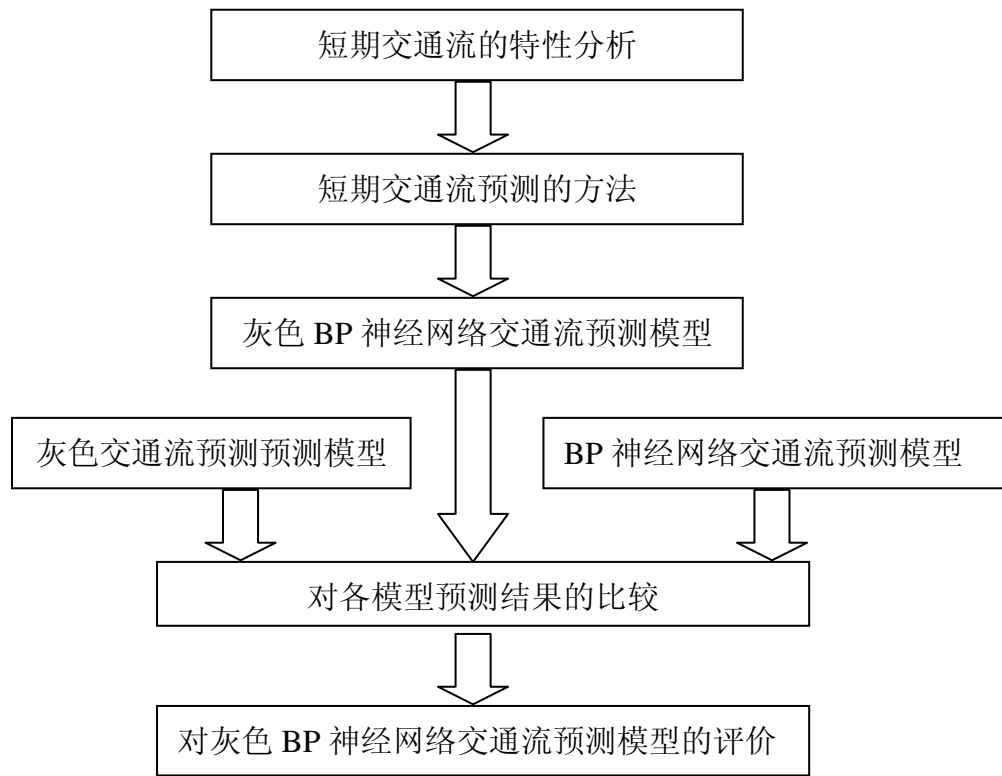


图 1-1 研究技术路线图

Fig.1-1 the route of research

第2章 基于灰色理论的交通流预测模型

2.1 交通流特性及预测方法分析

2.1.1 交通流预测方法及分类

在交通系统对交通流的预测亦有很长的历史了。但是，对于不同问题的研究中预测的目的不同，预测的时间跨度取值也存在较大的差异，对预测的侧重点、要求的精度都有所不同。

(1) 交通规划中的长期交通流预测

在对路网进行规划、设计中，需要对未来交通的需求量进行预测，以确定未来路网的规划方案，或在具体设计时，决定每条道路的具体设计要求。此时交通预测是对被规划的路网在使用期间的交通流量及其变化情况进行预测。这种预测一般以年为单位，即对未来若干年的路网或道路上的平均流量进行预测。由于规划设计只需对流量进行粗略的估计，所以长期交通流预测对预测的精度要求并不严格，同时由于长期需求规律性较强，因此使用常见的回归预测或弹性系数等方法均能满足要求。

(2) 以交通管理为目的的中期交通流预测

在制订交通管理的措施时，一般需要对一段时间内以月、日、小时为单位对交通流量分布进行估计，这种估计和预测是针对聚焦的宏观交通流，由于考虑问题的时间段较长，因此对于各种限制和影响可以忽略不计。这种中期预测虽然比长期预测的精度高，但由于交通流在不同区间内分布的规律性较强，这种预测的实现及达到所要求准确度不难实现。

(3) 以实时控制和引导为目的的短期交通流预测

由于控制和引导的变化较快，为控制和引导服务的交通预测，预测周期必须与控制及引导的周期相一致，这样预测时间跨度较前两种大大的缩小，一般不超过 15 分钟而随着预测周期的缩短，交通流变量的规律性越来越不明显，各种干扰所造成的影响就越来越大，这使短期交通流的变化显示出更明显的不确定性，因而也就决定了短时预测与中、长期预测相比，将面临更大困难。短期交通流的预测是 ITS 中一个无法回避的问题，实时准确的预测是 ITS 实现对交通高效率管理的前提和基础，预测问题解决的好坏，直接关系到控制与引

导的效果。

应用某一单一模型进行复杂交通流量的预测，由于各单一模型都各有优缺点和自己的适应条件。很难达到理想的预测效果，将不同的预测方法进行组合，能充分发挥各单一模型的优点，使预测的效果更好。

2.1.2 短期交通流的特性分析

一般而言短期交通流是统计时间间隔不超过 15min 的交通流时间序列。跨度不超过 15min 的交通流预测称为短期交通流预测。

(1) 交通流的网状特性：城市道路是一个立体网状结构，纵横交错且是互相联通的，每一条道路都有一定的交通流，整个交通流形似一个具有流动物质的网络。

(2) 交通流的时空特性：在不同时间、不同空间都会有不同情况的交通流出现，而且同一地点同一时间的交通流绝对不可替代另外一个时间和地点的交通流，这体现了交通流有着极强的时空特性。

(3) 交通流的随机性和时变特性：由于道路每个方向均存在左行、直行、右行三个车道，各个车道在不同时刻具有不同的车流量，车流行驶过程又是一种随机变化的不可控制的过程，所以交通流呈现出很大的随机性。而出行者在分析了道路的拥挤情况后，很可能调整出发时间，这样出行者出发和到达目的地的时间会发生时变，导致交通流高峰期随之发生时变。

(4) 交通流具有波动性，由于交通流受环境及时间的影响很大使交通流具有很强的波动性。比如受道路条件的影响，由于交通事故造成的交通拥挤，受天气影响造成的车流缓慢而使交通流量降低，受特殊事件比如集会，节假日出游等造成的交通量的增加，都反映了交通流的波动性。对于一天之内的交通高峰期与低峰期也同样反映了这一特性。

(5) 交通流具有非线性的特性和不确定性。由于车辆到达的随机性以及交通流的波动性等因素往往使交通流具有非线性的特性。交通流的运行被许多诸如车辆的特性、司机的心理因素、天气变化等不确定因素制约和左右着，因此交通流也体现出不确定性，且随着预测时间的缩短，其不确定性逐渐增强。

(6) 交通流的内在相关性：交通出行是一种有目的的需求，而不是一种完全无规律游走，因而存在一定的内在相关性。

(7) 交通流内在约定性：交通流的主体行为是一种理性驾驶，其中每个人——车个体追求的目标是一致的或者相近的，均为安全、快速、通畅，因而

存在相互协作、协同，并在宏观上形成一种有序结构的可能性，这种内在约定是交通流中形成自组织的重要原因。

(8) 交通流的长程相关性：交通流整体出行特性在时间上具有长程相关性和记忆性，即一旦城市布局和道路网确定，相应的，某条道路上的交通流整体特性也就基本确定，即交通流的出行特性具有一定的长程相关性和记忆性。

传统的交通流理论的明显特点是交通流模型的限制条件比较苛刻，模型推导过程比较严谨，模型的物理意义明确，如交通流分布的统计特性模型、车辆跟驰模型、交通流模型、车辆排队模型等。现代交通流理论是指以现代科学技术和方法为主要研究手段而形成的交通流理论，其特点是所采用的模型和方法不追求严格意义上的数学推导和明确的物理意义，而更重视模型或方法对真实交通流的拟合效果。这类模型主要用于对复杂交通流现象的模拟、解释和预测，而传统交通流理论要达到这些目的就显得困难。

2.2 灰色系统模型的原理及改进

2.2.1 灰色系统模型的原理

灰色系统理论是 1982 年由我国学者邓聚龙教授创立的，是一种研究少数数据、贫信息不确定性问题的新方法。灰色系统理论以“部分信息已知，部分信息未知”的“小样本”、“贫信息”不确定性系统为研究对象，主要通过对“部分”已知信息的生成、开发，提取有价值的信息，实现对系统运行行为，演化规律的正确描述和有效监控。灰色系统模型对实验观测数据没有什么特殊的要求和限制，因此应用领域十分宽广。社会、经济、农业、工业、生态、生物等许多系统，是按照研究对象所属的领域和范围命名的，而灰色系统却是按颜色命名的。人们常用“黑”表示信息未知，用“白”表示信息完全明确，用“灰”表示部分信息明确、部分信息不明确。与此相对的是白色系统为信息完全明确的系统，黑色系统为信息未知的系统，而部分信息明确、部分信息不明确的系统称为灰色系统。

对不确定性系统的研究方法，最常用的主要有：概率统计、模糊数学和灰色系统。这三者的共同点是研究系统的不确定性，但是由于系统的不确定性的不同也就产生了三种各具特色的不确定性学科。模糊数学研究的对象是“内涵明确，外延不明确”。概率统计研究的对象是“随机不确定”现象，考察的重点是“随机不确定”现象的历史统计规律，考察“随机不确定”现象中每一种

结果发生的可能性的。在研究的过程中要求大样本，并要求研究的对象是服从某种典型分布的。灰色系统理论研究的重点是解决概率统计和模糊数学所难以解决的“小样本”、“贫信息”不确定性问题，通过对数据的处理去探索事物运动的现实规律。其特点是“少数据建模”。

经过多年的发展灰色系统已经拥有多方面内容的结构体系。主要包括：基础的理论体系以灰色代数系统、灰色方程、灰色矩阵等为基础，以灰色序列生成为基础的方法体系，以灰色关联空间为依托的分析体系，以灰色模型（GM, Grey Model）为核心的模型体系，还有以系统分析、评估、建模、预测、决策、控制、优化为主体的技术体系。灰色模型通过灰色生成或序列算子的作用弱化随机性，挖掘潜在的规律，经过差分方程与微分方程之间的互换实现了利用离散的数据序列建立连续的动态微分方程的新飞跃。

灰色系统建模的原理是通过离散的时间序列数据建立近似连续的微分方程，采用的方法是通过序列生成算子生成一系列函数，这些函数是建模和预测的基础。这些算子的作用主要是强化离散过程的确定性，弱化其不确定性。这是灰色理论之所以能够利用少数据建模的最主要的原因。

道路交通体系是一个多层次、多因素、多目标的复杂系统，交通量信息系统更是具有明显的层次复杂性、动态变化的随时性、指标数据的不完全性和不确定性。由于检测方法、人为的因素、自然环境的因素对各种数据产生了误差、短缺甚至是虚假的现象，系统的规律不明确，系统的状态、结构、边界关系难以精确描述，这些都表明了交通信息系统是属于典型的灰色系统。

灰色预测可分为四种类型：

（1）灰色时间序列预测（又称为数列预测）：用观察到的反映预测对象特征的时间序列来构造灰色预测模型，预测未来某一时刻的特征量，比如粮食产量的预测，商品销售量的预测等。

（2）灾变预测：对系统行为特征量超出某个阈值（界限值）的异常值将在何时出现的预测称为灾变预测，其预测的任务不是确定异常值的大小，而是确定异常值出现的时间。

（3）拓扑预测：对一个变化不规则的行为数据序列未来的整体发展变化波形进行预测，因此又称为波形预测。

（4）系统预测：通过对系统行为特征指标建立一组相互关联的灰色预测模型来预测系统中众多变量间的相互协调关系的发展变化，如市场中代用产品、相互关联产品销售量互相制约的预测。

2.2.2 GM(1,1) 模型的改进

GM(1,1)模型是灰色理论中最典型的模型。符号的含义：G: grey(灰色), M: model(模型), (1, 1): 1 阶方程, 1 个变量。GM 模型的优点是算法简单, 运算速度快。对于短期预测能给出很好的预测效果, 但是对于具有波动性的系统预测的效果不是很理想, 交通流本身具有很多不确定性的因素, 受环境因素、突发事件的影响比较大, 具有很强的波动性。因此在短期交通流预测中预测的精度往往不高。

灰色预测是灰色系统理论技术的重要组成部分。GM(1,1)预测模型是迄今应用最为广泛的灰色模型之一。目前, GM(1,1)建模方法的研究主要集中在这几个方面展开: (1) 特殊序列的建模方法; (2) 提高灰色预测模型精度的方法; (3) GM(1,1) 模型的特性分析。

特殊序列建模方法, 特殊序列建模包括以下三个方面: (1) 含空缺值序列的建模。(2) 非等时距序列的建模, 常规 GM(1,1)建模的前提条件是建模序列必须满足等时距要求, 而在工程技术领域存在着大量的非等间距序列的数据拟合和预测问题。(3) 特殊灰色模型。

提高灰色预测模型精度的方法: 灰色模型的数据处理方法通常是累加生成、累减还原。由此建立起来的灰色模型, 其精度往往不能满足实际要求, 研究表明, 原始数据的模式及其光滑特性是影响灰色模型的两个主要因素, 于是形成三种提高灰色模型精度的方法: (1) 对原始数据进行变换, 改善其光滑特性, 并因此得到了一些变形的灰色模型和原始数据变换方法; (2) 对传统 GM(1,1)模型修正, 使之适应原始数据的特征; (3) 改进灰微分方程。由于实际问题中数据序列往往是复杂的、多种多样的, 因此需要 GM(1,1)扩展型。

2.3 基于灰色理论的交通流预测模型

2.3.1 灰色交通流预测模型的原始序列处理

系统中得到的数据序列, 往往是一组离散的数据, 灰色预测模型最终要建立的是一个近似的一元微分方程, 因此要求数据必须具有光滑性。为了能够利用系统中的这些离散的数据, 灰色理论采取了一种处理的方法, 就是利用各种算子。常用的算子有: 均值生成算子, 级比生成算子, 累加生成算子和累减生成算子。

本文采用累加生成算子和均值生成算子对原始序列进行处理。累加生成是使灰色过程由灰变白的一种方法，通过累加可以看出灰量积累过程的发展态势，使离乱的原始数据中蕴含的积分特性或规律充分显露出来。

设原始非负序列：

$$X^{(0)} = (x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)), \text{ 其中 } x^{(0)}(k) \geq 0, k = 1, 2, \dots, n$$

$$X^{(1)} = (x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n)), \text{ 其中 } x^{(1)}(k) = \sum_{i=1}^k x^{(0)}(i), k = 1, 2, \dots, n$$

再由 $X^{(1)}$ 生成紧邻均值生成序列 $Z^{(1)}$ 其中：

$$Z^{(1)} = (z^{(1)}(2), z^{(1)}(3), \dots, z^{(1)}(n)),$$

$$z^{(1)}(k) = 0.5(x^{(1)}(k) + x^{(1)}(k-1)), k = 2, 3, \dots, n. \quad (2-1)$$

2.3.2 灰色交通流预测模型的参数确定

GM(1,1) 的基本形式为：

$$x^{(0)}(k) + a z^{(1)}(k) = b \quad k = 1, 2, \dots, n \quad (2-2)$$

将数据代入 GM(1,1) 模型可得到一系列的方程如下：

$$\begin{aligned} x^{(0)}(2) + a z^{(1)}(2) &= b \\ x^{(0)}(3) + a z^{(1)}(3) &= b \\ \vdots \\ x^{(0)}(n) + a z^{(1)}(n) &= b \end{aligned}$$

即：

$$Y = B\hat{a}, \quad Y = \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \vdots \\ x^{(0)}(n) \end{bmatrix}, \quad B = \begin{bmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \vdots & \vdots \\ -z^{(1)}(n) & 1 \end{bmatrix} \quad (2-3)$$

对于 a, b 的一对估计值，以 $-a z^{(1)}(k) + b$ 代替 $x^{(0)}(k), k = 2, 3, \dots, n$, 可得误差序列：

$$\varepsilon = Y - B\hat{a} \quad (2-4)$$

设 $s = \varepsilon^T \varepsilon = (Y - B\hat{a})^T (Y - B\hat{a}) = \sum_{k=2}^n (x^{(0)}(k) + a z^{(1)}(k) - b)^2$ 使 s 最小的 a, b 应满足

$$\begin{cases} \frac{\partial s}{\partial a} = 2 \sum_{k=2}^n (x^{(0)}(k) + a z^{(1)}(k) - b) \cdot z^{(1)}(k) = 0 \\ \frac{\partial s}{\partial b} = -2 \sum_{k=2}^n (x^{(0)}(k) + a z^{(1)}(k) - b) = 0 \end{cases}$$

从而解得

$$\begin{cases} b = \frac{1}{n-1} \left[\sum_{k=2}^n x^{(0)}(k) + a \sum_{k=2}^n z^{(1)}(k) \right] \\ a = \frac{\frac{1}{n-1} \sum_{k=2}^n x^{(0)}(k) \sum_{k=2}^n x^{(0)}(k) z^{(1)}(k)}{\sum_{k=2}^n (z^{(1)}(k))^2 - \frac{1}{n-1} \left(\sum_{k=2}^n z^{(1)}(k) \right)^2} \end{cases} \quad (2-5)$$

由 $Y = B\hat{a}$ 得

$$B^T B \hat{a} = B^T Y, \hat{a} = (B^T B)^{-1} B^T Y \quad (2-6)$$

$$B^T B = \begin{bmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \vdots & \vdots \\ -z^{(1)}(n) & 1 \end{bmatrix}^T \begin{bmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \vdots & \vdots \\ -z^{(1)}(n) & 1 \end{bmatrix} = \begin{bmatrix} \sum_{k=2}^n [z^{(1)}(k)]^2 & -\sum_{k=2}^n z^{(1)}(k) \\ -\sum_{k=2}^n z^{(1)}(k) & n-1 \end{bmatrix}$$

$$(B^T B)^{-1} = \frac{1}{(n-1) \sum_{k=2}^n [z^{(1)}(k)]^2 - \left[\sum_{k=2}^n z^{(1)}(k) \right]^2} \cdot \begin{bmatrix} n-1 & \sum_{k=2}^n z^{(1)}(k) \\ \sum_{k=2}^n z^{(1)}(k) & \sum_{k=2}^n [z^{(1)}(k)]^2 \end{bmatrix}$$

$$B^T Y = \begin{bmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \vdots & \vdots \\ -z^{(1)}(n) & 1 \end{bmatrix}^T \begin{bmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \vdots \\ x^{(0)}(n) \end{bmatrix} = \begin{bmatrix} -\sum_{k=2}^n x^{(0)}(k) z^{(1)}(k) \\ \sum_{k=2}^n x^{(0)}(k) \end{bmatrix}$$

所以

$$\begin{aligned}\hat{a} &= (B^T B)^{-1} B^T Y = \frac{1}{(n-1) \sum_{k=2}^n [z^{(1)}(k)]^2 - \left[\sum_{k=2}^n z^{(1)}(k) \right]^2} \\ &\times \left[\begin{aligned} &-(n-1) \sum_{k=2}^n x^{(0)}(k) z^{(1)}(k) + \sum_{k=2}^n x^{(0)}(k) \sum_{k=2}^n z^{(1)}(k) \\ &-\sum_{k=2}^n z^{(1)}(k) \sum_{k=2}^n x^{(0)}(k) z^{(1)}(k) + \sum_{k=2}^n x^{(0)}(k) \sum_{k=2}^n [z^{(1)}(k)]^2 \end{aligned} \right] \\ &= \left[\begin{aligned} &\frac{1}{n-1} \sum_{k=2}^n x^{(0)}(k) \sum_{k=2}^n z^{(1)}(k) \sum_{k=2}^n z^{(1)}(k) - \sum_{k=2}^n x^{(0)}(k) z^{(1)}(k) \\ &\frac{\sum_{k=2}^n [z^{(1)}(k)]^2 - \frac{1}{n-1} \left[\sum_{k=2}^n z^{(1)}(k) \right]^2}{\frac{1}{n-1} \left[\sum_{k=2}^n x^{(0)}(k) + a \sum_{k=2}^n z^{(1)}(k) \right]} \end{aligned} \right] = \begin{bmatrix} a \\ b \end{bmatrix}\end{aligned}$$

方程: $\frac{dx^{(1)}}{dt} + ax^{(1)} = b$ 为 GM(1,1)模型

$x^{(0)}(k) + az^{(1)}(k) = b$ 的白化方程, 解此白化方程可以得到解:

$$x^{(1)}(t) = (x^{(1)}(1) - \frac{b}{a})e^{-at} + \frac{b}{a} \quad (2-7)$$

GM(1,1)模型 $x^{(0)}(k) + az^{(1)}(k) = b$ 的时间响应序列为:

$$\hat{x}^{(1)}(k+1) = (x^{(0)}(1) - \frac{b}{a})e^{-ak} + \frac{b}{a}; k=1, 2, \dots, n \quad (2-8)$$

还原值:

$$\hat{x}^{(0)}(k+1) = \alpha^{(1)} \hat{x}^{(1)}(k+1) = \hat{x}^{(1)}(k+1) - \hat{x}^{(1)}(k) = (1 - e^a)(x^{(0)}(1) - \frac{b}{a})e^{-ak}; k=1, 2, \dots, n \quad (2-9)$$

2.3.3 灰色交通流预测模型的适用条件

序列 x 的光滑比:

$$\rho(k) = \frac{x(k)}{\sum_{i=1}^{k-1} x(i)} \quad (2-10)$$

序列 x 为准光滑序列满足的条件:

$$(1) \frac{\rho(k+1)}{\rho(k)} < 1; k = 2, 3, \dots, n-1$$

$$(2) \rho(k) \in [0, \varepsilon]; k = 3, 4, \dots, n$$

$$(3) \varepsilon < 0.5$$

则称 X 为准光滑序列。在灰色预测模型中：

$$\rho(k) = \frac{x^{(0)}(k)}{x^{(1)}(k-1)} \quad (2-11)$$

2.4 灰色交通流预测模型算例

本章在构造算例利用的是某路段横断面间隔 5 秒的交通量数据。




图 2-1 灰色模型对原始数据的拟合

Fig.2-1 the Grey model imitating the original date




图 2-2 灰色模型对原始值的拟合

Fig.2-2 the Grey model imitating the original value

表 2-1 单一灰色模型对原始值的拟合误差分析

Table 2-1 the imitating error analysis of the single Grey model and the original value

数据点 i	1	2	3
原始值 w_i	48	49	52
拟合值 w'_i	47.1822	50.3621	53.7563
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	1.7%	-2.8%	-3.3%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	2.6%		

用灰色模型对原始序列进行拟合。分别给出各个点的交通量拟合以及各时间段内交通量的拟合。




图 2-3 各点灰色模型预测值
Fig.2-3 the Grey model predicting




图 2-4 灰色模型的预测
Fig.2-4 the prediction of the Grey model

表 2-2 灰色模型预测误差分析

Table 2-2 the prediction error analysis of the Grey model

数据点 i	1	2	3
原始值 w_i	55	57	66
拟合值 w'_i	57.3792	61.2466	65.3742
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	4.3%	-7.5%	0.9%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	4.2%		

用单一的灰色模型对原始序列进行预测，并分别给出了各点的拟合值以及相对原始序列的相对误差和平均误差。

2.5 本章小结

本章介绍了灰色预测模型的特点及其分类，并依据 GM(1,1)模型改进的方法对某路段横断面的交通量数据进行了拟合和预测。

第3章 基于神经网络的交通流预测模型

3.1 神经网络模型的原理

人工神经网络模型简称“神经网络”，神经网络以人脑神经元信息传递原理为参考模型，建立类似于人类在语言和图像处理等方面的行为。是在现代神经科学研究成果基础上提出的一种数学模型，是对大脑功能的一种简单的抽象和模拟。神经网络模型很多，具有以下几大特征：1) 大规模并行处理。神经元间传递信息的速度比计算机慢得多，但是人可以在一秒的时间内做出决策，传统的计算机是做不到这一点的。这是因为人脑的计算是经过大量的并行计算的。神经网络的大规模并行处理不仅是为了快，而且强调对决策有关的因素应同时处理；2) 容错性与鲁棒性。容错性指允许输入信息有畸变、缺损等；鲁棒性指网络少量元间的损坏不影响整体功能。人脑具有很强的容错性和联想功能，善于概括、类比、推广。大脑信息的存储，本质上不是局域式的，而是分布式的：每一信息记录在许多连接键上，这些连接键又同时记录许多不同的信息。在人脑的神经网络中，信息存储区与操作区合二为一，不同信息间的沟通是自然的。当然，分布式存储的信息之间的干扰也较大，因此，同样硬件条件下的存储容量，分布式存储远低于局域是存储；3) 可学习性或者称自适应性。大脑功能受先天因素制约，但是后天的学习、经历等也起很重要的作用。而用传统的人工智能原理编写的程序是很难完成训练的。

神经网络有两种运行方式，一是前传式，下面是输入层，最上是输出层，中间是有若干隐层。相邻层间有连接键相联，信息由下向上单向传递。连接强度可由学习算法不断调整，使之具有正确的输入—输出关系。反传播算法一定程度上解决了此问题，它本质上是一种误差函数的梯度下降算法，但是仍然存在效率低，易陷于局域极值等问题。

由于单层感知元模型的局限性，它无法完成一些复杂的分类问题和逻辑运算，如异或问题也不能解决；双层模型虽然解决了异或问题，但并没有解决其他复杂的分类问题；可以证明，只要增加一定规模的隐层，多层网络原则上可以实现任何输入—输出映射关系。3 层网络可形成输入信号的任何非线性连续函数。从理论上讲，对于给定的任意复杂的分类问题，只要适当选择隐结点的数目，再加上适当的学习算法，就可构造出需要的非线性映射。

学习的方式有很多，大致可分为“有导师学习”与“无导师学习”两类。前者属于死记硬背式学习；后者只是规定学习的方式，学习的具体内容随系统所处环境而异。

Hopfield 网络作为一种全连接型神经网络，曾经在人工神经网络研究发展历程中起过唤起希望、开辟研究途径的作用。它用与阶层型神经网络不同的结构特征和学习方法，模拟生物神经网络记忆机理，获得了令人满意的结果。基本思想是用人工神经元模拟的磁旋，用神经元之间的连接权模拟磁场中磁旋的相互作用；用各神经元的“激活”和“抑制”两种状态，模拟磁场中的磁旋的上、下两个方向，构成一个具有记忆功能的神经网络系统。

感知机的发明，曾使神经网络的研究迈出了历史性的一步。但是尽管感知机具有很出色的学习和记忆功能，可由于它只适用于线性模式的识别，对非线性模式的识别显得无能为力，甚至不能解决“异或”这样简单的非线性运算问题。虽然人们发现，造成感知机这种缺陷的主要原因是由于网络无隐含层作为输入模式的“内部表示”，并做了在输入层和输出层之间增加一层或多层因单元的尝试，但是当时还找不到一个适用于多层网络的行之有效的学习规则，甚至对是否存在这样一条规则抱有怀疑。目前应用最广，其基本思想最直观、最容易理解的多阶层神经网络即误差逆传播学习算法。有时也将按这一算法进行训练的多阶层神经网络直接称为误差逆传播神经网络。

神经网络是由许多并行的、高度相关的计算处理单元组成，这些单元类似生物神经系统的神经元。虽然单个的神经元的结构十分简单，但是，由大量神经元相互连接所构成的神经元系统所实现的行为是十分丰富的。与其它方法相比，神经网络具有并行计算和自适应的学习能力。神经网络模型有许多种类，经常使用的有 BP 网络，RBF 网络、Hopfield 网络、Kohonen 网络、BAM 网络等等，近年来又出现了神经网络与模糊方法、遗传算法相结合的趋势。该方法已在交通流预测中得到了应用。

3.2 基于 BP 神经网络的交通流预测模型

3.2.1 神经网络交通流预测的方法

在交通流预测中应用最早使用最多的是反传 BP 网络。误差逆传播神经网络是一种具有三层或三层以上的阶层型神经网络。上、下层之间各种神经元实现全连接，即下层的每一个单元与上层的每一个单元都实现权连接，而每层各

神经元之间无连接。网络按有教师示教的方式进行学习，当对学习模式提供给网络后，各神经元获得网络的输入响应。在这之后，按减小希望输出与实际输出误差的方向，从输出层经各中间层逐层修正各连接权，最后回到输出层，故得名“误差逆传播算法”。随着这种误差逆传播修正的不断进行，网络对输入模式响应的正确率也不断上升。

误差逆传播算法的基本思想是通过对网络参数的逐步调整实现网络学习的，它是在提供给网络的学习模式集合的全局误差按梯度下降的条件下达到网络记忆目的的，所以，当学习过程进行到全局误差开始有上升的趋势时就停止了，这往往导致网络误差陷入局部极小值，而达不到全局最小点，这种算法急于找到最小解，结果却是欲速则不达。导致网络学习过程陷入局部极小值的原因主要有两点：（1）网络结构上存在着输入与输出之间的非线性函数关系，从而使网络误差或能量函数所构成的空间是一个含有多极点的非线性空间；（2）算法上，网络的误差或能量函数只能按单方向减小而不能有丝毫的上升趋势。对于第一点，是为保证网络具有非线性映射能力而不可少的。

应用神经网络进行交通流预测的步骤如下：

第一步，根据实际情况，选择适当的网络结构作为预测工具，根据已确定的预测因子和被预测量，决定网络的输入和输出，进而决定网络的结构（网络个层次的节点数）；

第二步，准备样本数据和样本的规范化处理，样本分为训练样本和检验样本；

第三步，利用训练样本是对网络进行训练和学习；

第四步，利用检验样本对网络训练结构进行检验，验证网络的泛化能力；

第五步，利用训练好的网络，根据已知的数据进行实际预测。

与传统的预测方法相比，神经网络的预测方法的预测精度要好一些。这主要是得益于神经网络自身的特点。神经网络擅长描述具有较强非线性、难于用精确数学模型表达的复杂系统的特性，并且具有自适应能力。由于神经网络算法是离线学习，在线预测，所以几乎没有延时，实时性很好。此外，神经网络对预测因子的选择也较为灵活，任何认为与待预测交通流量有关的数据均可纳入输入向量中。但是神经网络也有一些弱点，主要表现在以下几个方面：

由于使用大量的样本进行训练，所以神经网络的学习训练过程收敛较慢，容易产生“过度学习”的情况，陷入对样本值的机械记忆而降低了泛化能力。因此，应用神经网络目前很难做到在线学习，只能将学习与预测分离成两个阶段来完成。

神经网络的训练与学习是基于训练样本所隐含的预测因子与被预测量的因果关系，这种学习不能反映外部环境的变化及其对预测的影响。因此，当预测对象所处的外部环境发生改变，或以某一路段数据训练好的神经网络去预测其它路段（口）的交通流量时，预测的准确率就会大大降低，错误率明显上升。这是由单一的神经网络的有限学习能力所决定的，表明经过训练的神经网络并不具有良好的“便携性”。

3.2.2 BP 神经网络模型

本文采用的 BP 神经网络是典型的三层、前馈阶层网络。即：输入层、隐含层（也称中间层）和输出层。各层之间实行全连接。BP 网络的学习，由四个过程组成：模式顺传播，误差逆传播，记忆训练，学习收敛。

（1）模式的顺传播

模式的顺传播过程是由输入模式提供给网络的输入层开始的。输入层各个单元对应于输入模式向量的各个元素。设输入向量为：

$$A_k = (a_1, a_2, \dots, a_n) \quad k = 1, 2, \dots, m; \quad m - \text{学习模式对数}, \quad n - \text{输入层单元个数}$$

对应输入模式的希望输出向量为：

$$Y_k = (y_1, y_2, \dots, y_q) \quad q \cdots \cdots \text{输出层单元数}$$

计算中间层各单元的输入。

$$s_j = \sum_{i=1}^n w_{ij} a_i - \theta_j \quad j = 1, 2, \dots, p \quad (3-12)$$

式中， w_{ij} —输入层之中间层的连接权；

θ_j —中间层单元的阈值；

p —中间层单元个数；

计算输出层各单元的输入、输出。

$$I_{jt} = \sum_{j=1}^n v_{jt} \cdot b_j - \gamma_t \quad (3-13)$$

$C_t = f(I_{jt}) \quad t = 1, 2, \dots, q$ 式中，

v_{jt} —中间层至输出层连接权；

γ_t —输出层单元阈值；

f —传递函数。

(2) 误差的逆传播

作为误差逆传播的第一步，是进行误差计算。误差逆传播过程是由输出层的误差 d ，向中间层的误差 e_i 传递的过程：

在这里输出层的校正误差按下式计算：

$$d_t^k = (y_t^k - C_t^k) f'(I_t) \quad t = 1, 2, \dots, q \quad k = 1, 2, \dots, m \quad (3-14)$$

$(y_t^k - C_t^k)$ 项表示网络希望输出与实际输出的绝对误差； $f'(L_t)$ 项根据各单元的实际响应调整偏差量。

为完成误差向中间层的传递，需要按下式计算中间层各单元校正误差：

$$e_j^k = \left[\sum_{j=1}^q v_{jt} \cdot d_t^k \right] f'(s_j) \quad j = 1, 2, \dots, p \quad k = 1, 2, \dots, m \quad (3-15)$$

得到校正误差 d_t^k 与 e_j^k 之后，沿逆方向调整输出层至中间层、中间层至输入层之间的连接权，以及各单元的输出阈值。其调整量的计算为：

$$\Delta v_{jt} = \alpha \cdot d_t^k \cdot b_j^k \quad (3-16)$$

$$\Delta \gamma_t = \alpha \cdot d_t^k \quad (3-17)$$

$$j = 1, 2, \dots, p \quad t = 1, 2, \dots, q \quad k = 1, 2, \dots, m \quad 0 < \alpha < 1 \quad (\text{学习系数})$$

$$\Delta w_{ij} = \beta \cdot e_j^k \cdot a_i^k \quad (3-18)$$

$$\Delta \theta_j = \beta \cdot e_j^k \quad 0 < \beta < 1 \quad (3-19)$$

(学习系数) $k = 1, 2, \dots, m$ 连接权的调整依赖于三个因素： α 、 d_t^k 和 b_j^k 。

首先，调整量与误差 d_t^k 成比例，即误差越大，调整的幅度也就越大。

其次，调整量与连接权所对应的中间层单元的输出值 b ，成比例。

(3) 训练过程

所谓训练过程，是指反复学习的过程，也就是根据教师示教的希望输出与网络实际输出的误差调整连接权的过程。而希望输出实际上是对输入模式分类

的一种表示，是人为设定的，所以也因人而异。随着“模式顺传播”与“误差逆传播”过程的反复进行，网络的实际输出逐渐向各自所对应的希望输出逼近。

(4) 收敛过程

前面已多次指出，学习或者说训练的收敛过程就是网络全局误差趋向于极小值的过程。

对于 BP 网络，其收敛过程存在着两个很大的缺陷：收敛速度慢；存在所谓“局部最小值”问题。在学习过程中有时会发现，当学习反复进行到一定次数以后，虽然网络的实际输出与希望输出还存在很大的误差，但无论再如何学习下去，网络全局误差的减少速度都变得十分缓慢，或者根本不再变化。这种现象就是因网络收敛于局部极小点所致。

(5) 对 BP 神经网络的改进

BP 算法的改进方法有两种途径，一种是采用启发式学习方法，另一种则是采用更有效的优化算法。本论文在利用 Matlab 进行编程时使用函数 `trainbpx()`，采用了动量法和学习率自适应调整的策略，从而提高了学习速度并增加了算法的可能性。动量法降低了网络对于误差曲面局部细节的敏感性，有效地抑制网络陷于局部极小。标准 BP 算法实质上是一种简单的快速下降静态寻优算法，在修正权值 $w(k)$ 时，只是按照 k 时刻负梯度方式进行修正，而没有考虑到以前积累的经验，即以前时刻的梯度方向，从而常常使学习过程发生振荡，收敛缓慢。为此提出了改进算法：

$$w(k+1) = w(k) + \alpha[(1-\eta)D(k) + \eta D(k-1)] \quad (3-20)$$

式中 $w(k)$ 既可表示单个的权值，也可表示权值向量； $D(k)$ 为 k 时刻的负梯度； $D(k-1)$ 为 $k-1$ 时刻的负梯度； α 为学习率， $\alpha > 0$ ； η 为动量因子， $0 \leq \eta < 1$ 。这种方法所加入的动量项实质上相当于阻尼项，它减小了学习过程的震荡趋势，从而改善了收敛性。自适应调整学习率有利于缩短学习时间。标准 BP 算法收敛速度慢的一个重要原因是学习率选择不当。改进算法如下：

$$w(k+1) = w(k) + \alpha(k)D(k); \alpha(k) = 2^\lambda \alpha(k-1); \lambda = \text{sign}[D(k)D(k-1)] \quad (3-21)$$

3.3 基于 BP 神经网络交通流预测模型算例

本章在构造算例时，同样是利用某路段横断面间隔 5 秒的交通量数据，对原始序列进行了拟合和预测。




Fig.3-1 the neural network model imitating the original

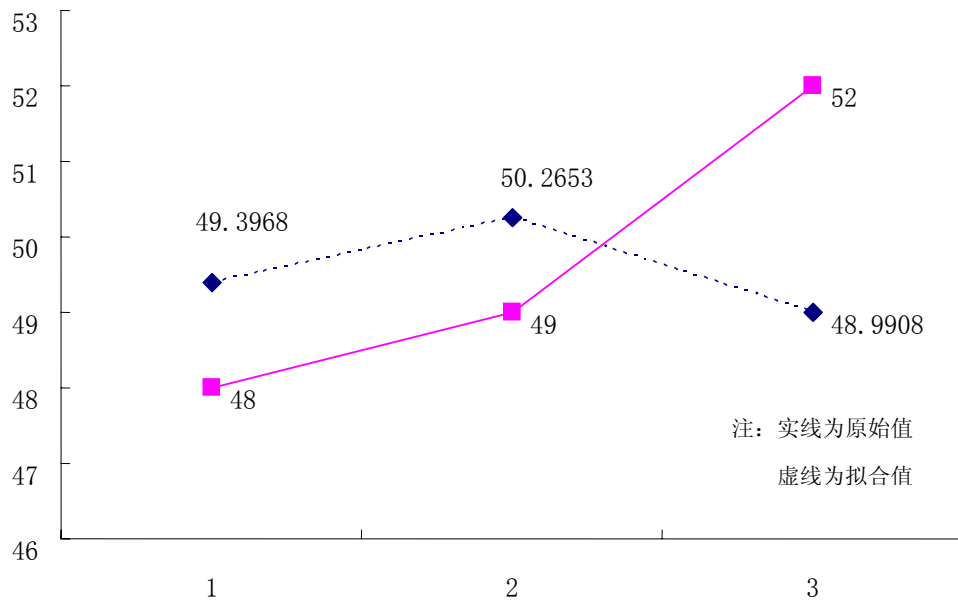


Fig.3-2 the neural network model imitating the original value

表 3-1 神经网络模型对原始值的拟合误差分析

Table 3-1 the imitating error analysis of single neural network model and the original value

数据点 i	1	2	3
原始值 w_i	48	49	52
拟合值 w'_i	49.3968	50.2653	48.9908
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	-2.9%	-2.6%	5.8%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	3.77%		

利用单一的 BP 神经网络模型对原始值进行拟合训练，同样利用前 30 个数据作为输入目标，后 30 个数据作为输出目标，为了比较各模型的预测效果，在设计单一的 BP 神经网络模型时与组合模型中的 BP 神经网络模型采用相同的参数。




图 3-3 BP 神经网络模型预测—各数据点的预测

Fig.3-3 the BP neural network model predicting—the individual point




图 3-4 神经网络模型预测

Fig.3-4 the neural network model forecast

表 3-2 神经网络模型预测误差分析

Table 3-2 the prediction error analysis of the neural network model

数据点 i	1	2	3
原始值 w_i	55	57	66
拟合值 w'_i	47.9289	46.5565	38.4953
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	12.9%	18.3%	41.7%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	24.3%		

利用训练好的单一 BP 神经网络模型对原始序列进行预测。按照设计的最大循环次数为 2000 次，并对预测结果进行了评价，分别给出了相对误差值和平均误差值。

3.4 本章小结

本章阐述了神经网络对非线性系统的良好预测的特点，同时对神经网络存在的缺点进行了分析，并利用单一神经网络对某路段横断面的交通量数据进行了拟合和预测。

第4章 灰色 BP 神经网络交通流预测模型

灰色 BP 神经网络模型是在利用灰色模型对短期交通流进行预测时，由于交通流系统具有很强的波动性，预测的效果不是很好，而 BP 神经网络可以通过预测值与实际值之间的残差序列对残差进行预测，BP 神经网络对非线性的预测可以达到很好的效果，进而对模型进行修正，可以使预测的精度得到很大的提高。从而建立一个组合模型，这样既可以发挥灰色预测模型运算速度快的特点，又能利用神经网络对非线性系统很好的进行预测的优点，最终取得令人满意的效果。在构建 BP 神经网络时，针对于交通流预测要求的时间段速度快的特点，注意了对 BP 神经网络算法的改进，采用动量法与自适应相结合加快网络的收敛速度避免误差陷入局部最小点。

4.1 基于灰色系统和神经网络的交通流预测模型

4.1.1 灰色系统与神经网络的融合

灰色预测模型，如 GM(1,1)预测模型、SCGM(1,1) 预测模型等可在小数据量情况下对非线性、不确定系统的数据序列进行预测。但是其预测误差往往偏高，特别是当系统中出现了突变、切换、故障或大扰动等情况特殊情况，对预测序列造成了干扰，就会出现异常数据，从而破坏了预测数据的平稳性，那么预测误差就会大幅上升。如果在预测控制系统中出现这种情况，就有可能导致控制器出现误操作，降低控制品质甚至出现事故。

与灰色预测模型相比，人工神经网络由于具有强大的学习功能，能够通过可对预测的突变数据进行学习，从而实现对某些特殊情况的出现进行预测。但是人工神经网络也有其弱点，那就是需要大量训练数据，训练数据不仅要求数量多，更重要的是具有广泛的代表性，这一点在实际工程中是比较难以满足的，而如果采用未经充分训练的人工神经网络来进行预测，其误差也会非常大。另一方面，如果用人工神经网络预测完全取代灰色预测，那么必须对在数据中占绝大部分的平滑数据进行训练，过多的训练模式必然要求更大的网络结构，从而降低了学习效率，也消耗了过多的资源，而少数特殊数据点的学习也可能被大量的正常数据湮没，使其不够突出。

4.1.2 灰色 BP 神经网络交通流预测模型的建立

从以上的分析可知，对于以平稳过程为主，但存在突变点的过程预测单独采用灰色预测或神经网络预测都不合适。因此本文提出以灰色预测为主，采用神经网络预测对其补偿的灰色—神经混合预测模型，以单输入单输出离散系统为例，令原始序列 $X(t) = \{x(t-k+i)\} (i=1,2,\dots,k)$ ，原始序列长度为 k ，预测步长为 l 。灰色预测采用 GM(1,1)。设 l 步后的预测值为 $\hat{x}(t+l)$ ，预测误差为：

$$e(t+l) = x(t+l) - \hat{x}(t+l)$$

在灰色—神经混合预测模型的学习过程中，神经网络采用多输入多输出 BP 网络，训练采用 BP 算法。

灰色预测模型，可在小数据量情况下对非线性、不确定系统的数据序列进行预测。但是其预测误差往往偏高，特别是当系统中出现了突变、切换、故障或大扰动等情况，对预测序列造成了干扰，就会出现异常数据，从而破坏了预测数据的平稳性，那么预测误差就会大幅上升。在实际系统中，虽然有些异常情况的出现是无法预期的，如故障、扰动等。但也有些突变点是通过之前的数据可以预测的，如正常情况下的有规律突变，预测数据出现极值点等情况，然而灰色预测模型，包括带误差补偿的灰色预测模型对这些数据是无法准确预测的。

与灰色预测模型相比，人工神经网络由于具有强大的学习功能，能够通过可对预测的突变数据进行学习，从而实现对某些特殊情况的出现进行预测。但是人工神经网络也有其弱点，那就是需要大量训练数据，训练数据不仅要求数量多，更重要的是具有广泛的代表性，这一点在实际工程中是比较难以满足的，而如果采用未经充分训练的人工神经网络来进行预测，其误差也会非常大。另一方面，如果人工神经网络预测完全取代灰色预测，那么必须对在数据中占绝大部分的平滑数据进行训练，过多的训练模式必然要求更大的网络结构，从而降低了学习效率，也消耗了过多的资源，而少数特殊数据点学习也可能被大量的正常数据淹没，使其不够突出。从以上分析可知，对于以平稳过程为主，但存在突变点的过程预测单独采用灰色预测或神经网络预测都不合适。因此本文提出以灰色预测为主，采用神经网络对其补偿的灰色 BP 神经网络模型。

首先在时间序列中时刻 L 的原始数据 $x^{(0)}(L)$ 与通过 GM(1,1)模型可以得到模拟值 $\hat{x}^{(0)}(L)$ 之差即残差，记为 $e^{(0)}(L) = x^{(0)}(L) - \hat{x}^{(0)}(L)$ 通过处理我们可以产生残差序列。

(1) 建立残差序列的 BP 网络模型。将得到的残差序列作为 BP 网络训练的输入样本；通过足够多的残差序列训练这个网络，使不同的输入向量得到相应的输出向量。这样网络的权系数值、阈值等，便是网络经过自适应学习所得的训练值。从而可以利用网络对残差序列进行预测。

(2) 通过训练的 BP 神经网络可以对残差做出预测，可得到残差的预测值，利用这一预测值构造新的预测值 $\hat{X}^{(0)}(i,1) = \hat{X}^{(0)}(i) + \hat{e}^{(0)}(1)$

$\hat{X}^{(0)}(i,1)$ 就是灰色 BP 神经网络组合模型的预测值。

4.2 灰色 BP 神经网络交通流预测模型的程序实现

根据构造的预测组合模型，利用某路段收集的实际交通量数据进行仿真。所收集的数据，是对某路段高峰时段进行观测，得到的间隔 5 秒的横断面的交通量。编程的主要内容：

(1)数据处理。通过累加算子，累减算子以及均值生成算子由原始数据生成新的序列。

(2)GM(1,1)模型的建立。

(3)BP 神经网络输入对的生成，由原始数据与预测数据的偏差构成。

(4)BP 神经网络的设计。

(5)灰色 BP 神经网络组合模型生成。

(6)单一的灰色预测模型

(7)单一的神经网络模型

其中(6)和(7)是单独编程的。对各预测模型的结果进行比较分析，从预测精度和预算时间上。本文编程的环境是基于 Matlab6.5 应用软件。

编程的思路分为以下几个步骤：

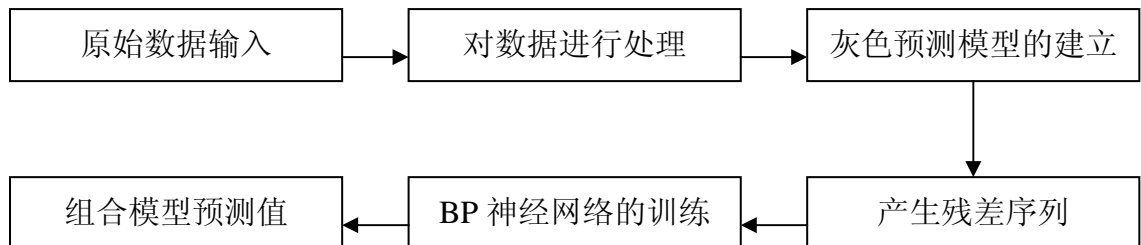


图 4-1 编程的思路

Fig.4-1 the route of program

本文在构造神经网络时采用的是三层、前馈神经网络每一层选用的神经单元个数分别为 4、10、1。输入层和隐含层采用 `tansig` 函数，输出层采用 `purelin` 函数，最大循环次数取为 2000 次。本文所利用的数据为某路段横断面间隔 5 秒的交通量数据，在对神经网络进行训练时输入目标为前 30 个数据，输出目标为后 30 个数据。所进行的预测并不是强调某一个时间点；某一时刻的预测，而是对时间段内交通流量的预测，更确切的说是一种趋势的预测，而这种趋势也是仅对于时间段内而言的。这样做的原因是因为交通流本身就具有波动性的特点，如果将时间段放大则这种特点就表现为交通流的高峰期和低峰期。所以如果单纯去预测某一时刻某一点的交通流量是不够准确的。在以下的实验中我们分别对组合模型，单一的 BP 神经网络模型，单一的灰色模型进行了测试。并对各种模型的预测结果进行了对比。对于拟合实验我们选取前 60 个数据来进行。对于预测我们选取的是对 60-90 个数据而进行的。对于组合模型和单一的灰色模型在预测时，预测的精度上相差不大，我们进一步对下一时段进行了预测即数据系列的 90-120 个数据点。

4.3 灰色 BP 神经网络交通流预测模型的应用分析

4.3.1 原始数据序列的拟合及预测




图 4-2 原始值的拟合—各数据点的拟合

Fig.4-2 the compounding model imitating the original value —the individual point




图 4-3 原始值的拟合

Fig.4-3 imitating the original value

表 4-1 原始值的拟合误差分析

Table 4-1 the error analysis of imitating the original value

数据点 i	1	2	3
原始值 w_i	48	49	52
拟合值 w'_i	46.3291	50.1925	54.305
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	3.5%	-2.4%	-4.4%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	3.43%		

首先利用前 60 个数据点对模型进行训练。数据分为两组，前 30 个数据作为输入目标，后 30 个数据作为输出目标，然后对后 30 个数据进行拟合。取 10 个数据点为一个拟合时间段即 50 秒，这样我们得到 3 个拟合值。预测的结果如图 4-3 所示，并对数据的相对误差和平均误差进行了计算。相对误差为各预测值相对于原始值的误差，平均误差为各拟合点的平均值。




图 4-4 预测值—各数据点的预测

Fig.4-4 the prediction value —the individual point




图 4-5 预测值和原始值

Fig.4-5 the value of prediction and the original value

表 4-2 预测值误差分析

Table 4-2 the error analysis of prediction and original value

数据点 i	1	2	3
原始值 w_i	55	57	66
预测值 w'_i	56.8498	61.4146	65.8448
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	-3.4%	-7.8%	-0.24%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	3.81%		

利用训练出来的模型对 60-90 个数据进行预测并与原始值进行比较。同样用相对误差和平均误差两项指标对预测结果进行了评价。

4.3.2 灰色 BP 模型与灰色模型和 BP 模型的比较

我们分别对组合模型，单一 BP 神经网络模型，单一灰色模型的拟合和预测效果进行了比较。对于拟合，单一灰色模型的拟合效果最好，其次是组合模型，单一 BP 神经网络模型的预测精度最低。平均误差分别为：2.6%，3.43%，3.77%。对于预测，组合模型的预测最好，其次是单一灰色模型，最后

是单一的 BP 神经网络模型。平均误差分别为：3.81%，24.3%，4.2%。从以上的实验我们可以看出，利用组合模型和单一灰色预测模型对预测能取得比较理想的预测效果，但是利用单一的 BP 神经网络在最大训练次数限定为 2000 次的情况下，与组合模型和单一的灰色模型的预测效果相比不够理想。而且在组合模型中，BP 神经网络部分的设计与单一 BP 神经网络的设计参数是相同的，可见组合模型的预测效果优于单一 BP 神经网络模型。对于单一的 BP 神经网络模型如果想进一步提高精度，那么必然要增加循环次数，这同时也就增加了网络的运行时间。对于单一的灰色模型，从预测的效果看与组合模型相差的不多，为了使对比的效果更加明显，我们进行了进一步的实验，我们利用两种模型对相隔时段的交通量进行了预测。这里我们把拟合所用的数据作为第一时段，将相邻时段作为预测时段，而将下一时段作为相隔阶段。之所以要做这样的实验是因为，单一灰色模型对于具有波动性的系统预测的效果不是很理想。而组合模型通过 BP 神经网络的调整对于具有波动性的系统可以做出调整。以下为实验的结果。

4.3.3 对灰色 BP 模型和单一灰色预测模型的进一步比较




图 4-6 灰色 BP 模型对下一时段的预测

Fig.4-6 the Grey and BP model predicting the next period

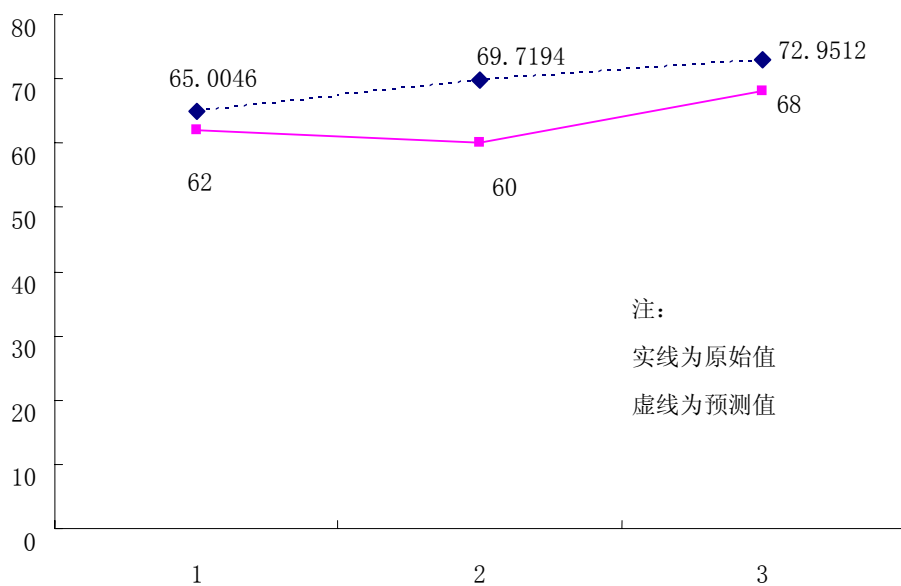


图 4-7 灰色 BP 模型对下一时段的预测

Fig.4-7 the Grey and BP model predicting the next period

表 4-3 组合模型对下一时段的预测误差分析

Table 4-3 the prediction error analysis of compounding model and the next period

数据点 i	1	2	3
原始值 w_i	62	60	68
预测值 w'_i	65.0046	69.7194	72.9512
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	-4.8%	-16.2%	-7.3%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	9.43%		




图 4-8 灰色模型对下一时段的预测

Fig.4-8 the Grey model predicting the next period




图 4-9 灰色模型对下一时段预测

Fig.4-9 the Grey model predicting the next period

表 4-4 单一灰色模型对下一时段的预测误差分析

Table 4-4 the prediction error analysis of the single Grey model and the next period

数据点 i	1	2	3
原始值 w_i	62	60	68
预测值 w'_i	69.3672	74.4813	79.503
相对误差 $\mu_i = \frac{w_i - w'_i}{w_i}$	-11.9%	-24.1%	-16.91%
平均误差 $\sigma = \frac{\mu_1 + \mu_2 + \mu_3}{3}$	17.63%		

通过实验得出的结果我们看到，组合模型的平均误差为 9.43%，单一灰色模型的误差为 17.63%。组合模型对于波动性的系统的调整比单一灰色模型好的多。而且单一灰色模型的缺点就是随着时间的推移，其偏离系统的误差越来越大。

根据以上实验数据我们可以看出，灰色 BP 神经网络模型与单一的 BP 神经网络和单一灰色模型相比有以下优点：可以快速的建立模型并可以达到满意的预测精度。实验证明了在组合模型中的神经网络模型和单一 BP 神经网络模型中的参数相同的情况下，组合模型能取得更好的预测效果，而在相同的循环次数（2000 次）的条件下，单一 BP 神经网络预测的平均误差很大。为了提高 BP 神经网的预测精度，可以增加网络的最大循环次数，这就相应的增加了网络的运算时间。与单一灰色模型相比，在对相邻时段的预测中，精度相差不大，在对相隔时段内的预测中，组合模型表现了更好的适应性。单一灰色模型主要的是对系统的一种趋势的预测，对于具有波动性的系统来说，仅有这种预测趋势是不够的，而且系统的变化的趋势往往不是稳定的。组合模型通过 BP 神经网络的调整能有效的减少因此产生的误差。可见利用灰色模型对系统趋势的预测以及通过神经网络对趋势变化的调整，建立的灰色 BP 神经网络模型是有效的和可行的，而且具有精度高和样本少的优点。

4.4 本章小结

本章的主要内容是通过某路段实际收集的交通流数据，进行了组合模型对交通流的仿真和预测实验，并分别与单一的 BP 神经网络模型和单一的灰色预测模型进行了比较。试验中，对每一种模型都进行了仿真和预测的实验。并对仿真和预测的结果进行了误差分析。得出了组合模型优于单一模型的结论。

结论

短期交通流预测问题，是 ITS 智能交通系统中的热门问题之一，它能为交通诱导和控制提供可靠的数据，是系统对下一刻的道路交通做出合理的诱导和控制的关键。对于现有大多数短期交通流预测模型，存在着模型的算法复杂，要求使用大量的数据的缺点。本文在总结了国内外短期交通流预测模型特点的基础上，针对灰色预测模型算法简单，运算速度快，对短期预测精度高以及 BP 神经网络对非线性系统具有良好的预测效果的特点，提出了以灰色预测为主，通过 BP 神经网络进行修正的组合模型。在此研究过程中，得出以下结论和创新点：

(1) 利用灰色模型建模使用数据少，运算速度快的特点以及利用 BP 神经网络对非线性系统具有很好的预测效果的特性，通过 BP 神经网络来修正灰色预测模型，建立了一个组合模型。既提高灰色预测模型对交通流系统的预测精度，又与单一的 BP 神经网络相比所使用的数据较少。

(2) 通过利用在某路段收集的实际交通流数据，进行了组合模型和单一灰色模型以及单一 BP 神经网络模型的仿真实验。并对实验的结果进行了分析比对。最后我们得出了组合模型优于单一模型的结论。组合模型能够充分发挥各单一模型的优点，但是组合模型也不能完全避免单一模型的缺点。在灰色 BP 神经网络模型中由于灰色模型对系统的趋势预测仅对相邻时段具有很好的预测精度，而随着时间推移预测的结果往往会与实际序列的趋势相偏离，尤其对于具有波动性的系统。

(3) 依据短期交通流的特性以及交通系统的灰色属性决定了在交通流预测中需采用灰色 BP 预测模型。

总结以上经验，对于组合模型提出值得进一步进行研究的方面是：能够使模型实时的进行预测并能保证一定的预测精度；确定合理的样本数量，使组合模型中的神经网络模型的精度进一步提高，同时能保证较快的运算速度。

参考文献

- 1 Bart Van Arem, Howard R, Kirby, Martie J.M, Van Der Vlist. Recent advances and application in the field of short-term traffic forecasting. *International Journal of Forecasting* .1997(9),13:1~12
- 2 Corinne Ledoux. An Urban Traffic Flow Integrating Neural Networks. *Transportation Part C*. 1997,5(5):287~300
- 3 Haibo Chen, Susan Grant-Muller. Use of sequential learning for short-term traffic flow. *Transportation Research Part C*. 2001,9:319~336
- 4 C. Quek, A. Singh. POP-Yager: A novel self-organizing fuzzy neural network based on the Yager inference. *Expert Systems with Application*. 2005,29:229~242
- 5 初连禹, 杨兆升. 基于神经网络的实时交通流量模糊预测. *中国公路学报*. 1998,11:78~82
- 6 王宏杰, 林良明, 颜国正. 基于改进BP网交通流动态时序预测算法的研究. *交通与计算机*. 2001,3(19):11~14
- 7 谭国真, 丁浩. 广义神经网络的研究及其在交通流预测中的应用. *控制与决策*. 2002,11(17):777~781
- 8 李英, 李武, 王浣尘. 一种基于演化神经网络的预测算法. *预测*. 2003,22(6):66~69
- 9 杨世坚, 贺国光. 基于模糊C均值聚类 and 神经网络的短视交通流预测方法. *系统工程*. 2004,8(22):83~86
- 10 孙燕, 陈森发. 灰色系统理论在无检测交叉交通流量预测中的应用. *东南大学学报*. 2002,2(32):256~258
- 11 陈淑燕, 陈家胜. 一种改进的灰色模型在交通量预测中的应用. *公路交通科技*. 2004,2(21):79~82
- 12 S-Y Yun, S. NAMKOONG. A Performance Evaluation of Neural Network Models in Traffic Volume Forecasting. *Mathl Comput* .1998, Modelling Vol 27:293~310
- 13 Hongbin Yin, S.C. Wong, Jianmin Xu, C. K. Wong. Urban traffic flow prediction using a fuzzy-neural approach. *Transportation Research Part C*. 2002,10:85~98
- 14 M. Mozolin, J.-C. Thill, E. Lynn Uesry. Trip distribution forecasting with multilayer perceptron neural network: A critical evaluation. *Transportation Research Part B*. 2000,34:53~73
- 15 Fengxiang Qiao, Hai Yang, William H.K. Lam. Intelligent simulation and prediction of traffic flow dispersion. *Transportation Research Part B*. 2001,35:843~863
- 16 Hussein Dia. An object-oriented neural network approach to short-term traffic

- forecasting. *European Journal of Operation Research*. 2001,131:253~261
- 17 朱中, 杨兆升. 实时交通流量人工神经网络预测模型. *中国公路学报*. 1998,4(11):89~92
 - 18 杨立才, 贾磊. 粗神经网络及其在交通流预测中的应用. *公路交通科技*. 2004,10(21):95~98
 - 19 杨世坚, 贺国光. 基于模糊C均值聚类 and 神经网络的短视交通流预测方法. *系统工程*. 2004,8(22):83~86
 - 20 凌浩, 陈峻, 王炜. 用BP神经网络预测下游交叉口进口交通量. *产业经济与管理*. 2005,01-0038-03
 - 21 华冬冬, 陈森发. 一种改进的神经网络及其在交通流预测中的应用. *交通科技*. 2005,1:71~73
 - 22 王殿海, 严宝杰. 交通流理论. 人民交通出版社. 2002: 66~92
 - 23 王炜. 交通工程学. 东南大学出版社. 2002: 71~102
 - 24 杨兆升. 城市交通流诱导系统与模型. 人民交通出版社. 2000: 106~132
 - 25 李锋, 邓聚龙. 灰色系统理论的发展概况. *信息与开发*. 2000,3:6~9
 - 26 谭冠军. GM(1,1)模型的背景值构造方法和应用(I). *系统工程理论与实践*. 2000,20(4):98~103
 - 27 高文志. 人工神经网络的发展、研究内容及应用综述. *山东电子*. 1998,12(4):3~4
 - 28 高洪深, 陶有德. BP神经网络模型的改进. *系统工程理论与实践*. 1996,1(1):67~71
 - 29 王文剑. BP神经网络模型的优化. *计算机工程与设计*. 2000,21(6):8~10
 - 30 刘光中, 李晓峰. 人工神经网络BP算法的改进和结构的自调整. *运筹学学报*. 2001,5(1):81~88
 - 31 刘思峰, 郭天榜, 党耀国. 灰色系统理论及其应用. 科学出版社. 1999
 - 32 Wang Zhongdong. Grey prediction control for the pelleter. *The Journal of Grey System*. 1997,9(2):167~174
 - 33 Jen-Yang Chen. Stable Grey Prediction Controller Design. *The Journal of Grey System*. 1997,1(4):335~349
 - 34 Ming-Feng yeh, Hung-Ching Lu. A New Modified Grey Model. *The Journal of Grey System*. 1996,8(3):209~216
 - 35 Liu Xiqiang. The Grey GM Model and its Applications. *Systems Science Theory and Practice*. 1995,15(1):59~62
 - 36 Pineda. F.J. Generalization of back-propagation to recurrent neural networks [J]. *Physical Rev Lett*. 1987,59:2229~2232
 - 37 K.S.Narendra and K. Parthasarathy. Gradient methods for the optimization of dynamical

- systems containing neural networks,IEEE Trans.Nerual Networks. 1991,2(1):252~262
- 38 S.Y. Yun., S. Namkoong. A Performance Evaluation of Neural Network models in Traffic Volume Forecasting. Mathematical and Computer Modeling. 1998,27(6):293~310.
- 39 S. Haykin. Neural Networks, A Comprehensive Foundation.New Jersey:Prentice-Hall,Inc,1997, 19(3):222~237.
- 40 L. Smith,Brian; J. Demetsky,Michael. Traffic flow forecasting:comparison of modeling approaches.Journal of Transportation Engineering v, 1997, 123July/Aug:261~266
- 41 M. Dougherty, M. Cobbett. Short-term inter-urban traffic forecasts using neural network..International, 1997,Journal of Forecasting 13:21~31.
- 42 R. Hecht-Nielsen. Theory of the back propagation neural network [C].1998, Proc, of IJCNN, 1:593~603
- 43 Baher Abdulhai, Himanshu Porwl, Will Recker. Short-term Traffic flow prediction using neuro-genetic algorithms, 2002, ITS Journal,7:3~41

附录

1 组合模型拟合原始序列程序

```
%灰色 BP 神经网络交通流预测程序设计
%第一部分：灰色预测模型的建立
X=input('输入交通流序列矩阵： ');
X1=cumsum(X);
A='已生成了一阶累加生成算子';
disp(A);
pause(2);
disp(X1);
A0='判断序列是否为准光滑，如果是则进行下一步，不是则继续做累加生成';
disp(A0);
k=max(size(X));
l=3;
p=X(l)/X1(l-1);
if p>0.5
    l=l+1;
    if l>=5;
        M=X1;
        X1=cumsum(X1);
        X=M;
        l=1;
    end
end
disp(X1);
A1='在此基础上再做一次紧邻均值生成序列';
disp(A1);
pause(2);
Z=zeros(1,k-1);
Z(1:k-1)=0.5*(X1(2:k)+X1(1:k-1));
```

```

disp(Z);
A2='计算模型中的参数 a 和 b 的值';
disp(A2);
Y=X(2:k);
B=[-Z',ones(k-1,1)];
aa=inv(B'*B)*(B'*Y);
a=aa(1)
b=aa(2)
A3='GM(1,1)模型的时间响应序列为:';
disp(A3);
F=zeros(1,k);
i=1;
while i<=k;
F(i)=(X(1)-b/a)*exp(-a*(i-1))+b/a;
i=i+1;
end
disp(F);
E='还原值为';
disp(E);
G=zeros(1,k);
j=1;
while j<=k;
G(j)=(1-exp(a))*(X(1)-b/a)*exp(-a*(j-1));
j=j+1;
end
disp(G);
%第二部分：误差的神经网络预测
E=G-X;
net=newff([-7 7],[4 10 1],{'tansig' 'tansig' 'purelin'},'traingdx')
p=E(1:30)
t=E(31:60);
net.trainParam.epochs=2000;
net.trainParam.lr=0.05;

```

```

net.trainParam.lr_inc=1.05;
net.trainParam.goal=1e-5;
[net,tr]=train(net,p,t);
n=X(1);
X2=zeros(1,30);
    v33=sim(net,p);
    X2(1:30)=G(31:60)+v33;
end
disp(v33);
disp(X2);
x1=zeros(1,30);
for t=5:5:150
    x1(t/5)=t;
end
plot(x1,X(31:60),x1,X2);
W1=sum(X(31:60))
W2=sum(X2)
E=(W2-W1)/W2

```

2 组合模型对原始序列预测程序

%第一部分：灰色预测模型的建立

X=input('输入交通流序列矩阵： ');

X1=cumsum(X);

A='已生成了一阶累加生成算子';

disp(A);

pause(2);

disp(X1);

A0='判断序列是否为准光滑，如果是则进行下一步，不是则继续做累加生成';

disp(A0);

k=max(size(X));

l=3;

p=X(l)/X1(l-1);

if p>0.5

```

        l=l+1;
    if l>=5;
        M=X1;
        X1=cumsum(X1);
        X=M;
        l=1;
    end
end
disp(X1);
A1='在此基础上再做一次紧邻均值生成序列';
disp(A1);
pause(2);
Z=zeros(1,k-1);
Z(1:k-1)=0.5*(X1(2:k)+X1(1:k-1));
disp(Z);
A2='计算模型中的参数 a 和 b 的值';
disp(A2);
Y=X(2:k);
B=[-Z',ones(k-1,1)];
aa=inv(B'*B)*(B'*Y');
a=aa(1)
b=aa(2)
A3='GM(1,1)模型的时间响应序列为: ';
disp(A3);
F=zeros(1,k);
i=1;
while i<=k;
    F(i)=(X(1)-b/a)*exp(-a*(i-1))+b/a;
    i=i+1;
end
disp(F);
E='还原值为';
disp(E);

```

```

G=zeros(1,k);
j=1;
while j<=k;
G(j)=(1-exp(a))*(X(1)-b/a)*exp(-a*(j-1));
j=j+1;
end
disp(G);
%第二部分：误差的神经网络预测
E=G-X;
net=newff([-7 7],[4 10 1],{'tansig' 'tansig' 'purelin'},'traingdx')
p=E(1:30);
t=E(31:60);
net.trainParam.epochs=2000;
net.trainParam.lr=0.05;
net.trainParam.lr_inc=1.05;
net.trainParam.goal=1e-5;
[net,tr]=train(net,p,t);
n=X(1);
X2=zeros(1,30);
H=zeros(1,30);
for r=91:120;
    H(r-90)=(1-exp(a))*(X(1)-b/a)*exp(-a*(r-1));
end
p=[2,5,6,4,8,6,7,5,6,6,4,5,6,5,6,8,6,5,7,5,5,7,7,8,6,6,8,5,8,6];
v33=sim(net,p);
X2=H+v33;
disp(v33);
disp(X2);
x1=zeros(1,30);
for t=5:5:150
    x1(t/5)=t;
end
T=[3,5,6,5,7,7,6,8,8,7,6,7,7,6,4,7,6,8,4,5,7,8,5,8,5,7,5,7,8,8]

```



```
plot(x1,T,x1,X2);
```

```
W1=sum(T)
```

```
W2=sum(X2)
```

```
E=(W2-W1)/W2
```

3 单一灰色模型程序

```
X5=zeros(1,30);
```

```
for j=1:30
```

```
    X5(j)=(1-exp(a))*(X(1)-b/a)*exp(-a*(j+90));
```

```
end
```

```
end
```

```
disp(X5);
```

```
T=[3,5,6,5,7,7,6,8,8,7,6,7,7,6,4,7,6,8,4,5,7,8,5,8,5,7,5,7,8,8]
```

```
w1=sum(X5)
```

```
w2=sum(T)
```

```
E=(w2-w1)/w2
```

```
for t=5:5:150
```

```
    V1(t/5)=t;
```

```
end
```

```
plot(V1,T,V1,X5);
```

5 单一 B P 神经网络模型程序

```
X=input('输入矩阵')
```

```
net=newff([0 10],[4 10 1],{'tansig' 'tansig' 'purelin'},'traingdx')
```

```
p=X(1:30);
```

```
t=X(31:60);
```

```
net.trainParam.epochs=2000;
```

```
net.trainParam.lr=0.05;
```

```
net.trainParam.lr_inc=1.05;
```

```
net.trainParam.goal=1e-5;
```

```
net.trainParam.min_grad=1e-5;
```

```
[net,tr]=train(net,p,t);
```

```
X2=zeros(1,30);
```

```
p=X(1:30);
```

```
v33=sim(net,p);
```

```
disp(v33);
x1=zeros(1,30);
for t=5:5:150
    x1(t/5)=t;
end
W=[4,5,4,4,5,4,5,5,7,5,4,3,5,6,7,5,4,6,5,4,5,6,6,4,5,7,5,4,6,4]
plot(x1,v33,x1,W);
W1=sum(v33);
W2=sum(W);
E=(W2-W1)/W2;
```

攻读学位期间发表的学术论文

安实, 王健, 陈纲. 基于灰色理论和 BP 神经网络的交通流预测模型. 交通科技. 已投

哈尔滨工业大学硕士学位论文原创性声明

本人郑重声明：此处所提交的硕士学位论文《基于灰色理论和 BP 神经网络交通流预测模型研究》，是本人在导师指导下，在哈尔滨工业大学攻读硕士学位期间独立进行研究工作所取得的成果。据本人所知，论文中除已注明部分外不包含他人已发表或撰写过的研究成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。本声明的法律结果将完全由本人承担。

作者签字：日期： 年 月 日

哈尔滨工业大学硕士学位论文使用授权书

《基于灰色理论和 BP 神经网络交通流预测模型研究》系本人在哈尔滨工业大学攻读硕士学位期间在导师指导下完成的硕士学位论文。本论文的研究成果归哈尔滨工业大学所有，本论文的研究内容不得以其它单位的名义发表。本人完全了解哈尔滨工业大学关于保存、使用学位论文的规定，同意学校保留并向有关部门送交论文的复印件和电子版本，允许论文被查阅和借阅，同意学校将论文加入《中国优秀博硕士学位论文全文数据库》和编入《中国知识资源总库》。本人授权哈尔滨工业大学，可以采用影印、缩印或其他复制手段保存论文，可以公布论文的全部或部分内容。

作者签名：日期： 年 月 日

导师签名：日期： 年 月 日

哈尔滨工业大学硕士学位涉密论文管理

根据《哈尔滨工业大学关于国家秘密载体保密管理的规定》，毕业论文答辩必须由导师进行保密初审，外寄论文由科研处复审。涉密毕业论文，由学生按学校规定的统一程序在导师指导下填报密级和保密期限。

本学位论文属于 保密□，在 年解密后适用本授权书
不保密□

(请在以上相应方框内打“√”)

作者签名：日期： 年 月 日

导师签名：日期： 年 月 日

致谢

本论文是在导师王健副教授和师兄谢秉磊博士后悉心指导和热忱关心下完成的。在攻读硕士学位期间，导师及师兄的亲切关怀和言传身教渗透进了我的生活、学习和研究中的点点滴滴，是他们引导和鼓励我在学科发展的前沿领域积极探索、不断进取。我的每一点进步、每一次成功无不凝聚着他们的心血和汗水，无不包含着他们的鼓励和支持。他们朴实无华的作风，高尚的思想情操，和蔼可亲的性格以及开拓进取的精神使我在潜移默化的感召中学会了做人做事：他们严谨求实，精益求精的治学态度，渊博的知识，敏锐的洞察力，对问题的独到的见解以及对科学孜孜不倦的追求精神将使我受益终身。在此作为导师的学生和师兄的学弟我对您们表示最崇高的敬意、最诚挚的感谢和最真心的祝福！

同时感谢各位师弟们：赵雪松、丁正飞、杜先睿、朱权、刘宝、陈杰、张峰。感谢他们对我的帮助和支持，是他们伴随着我度过了这一段难忘的求学时光。

感谢各位专家教授在百忙中评阅此论文。

最后，还要感谢我的家人，感谢他们多年来给予我的关心、鼓励、理解和支持。

谨以此段文字献给所有关心、支持和帮助过我的人们！